

Regresión Logística: Estimación por Máxima Verosimilitud, Inferencia Asintótica y Diagnóstico de Linealidad en el Logit

Notas de estudio — nivel ISLR / teoría de verosimilitud

July 2, 2026

Contents

1	Introducción y objetivo	3
2	El modelo logístico	3
2.1	Planteamiento y motivación del enlace	3
2.2	Interpretación de los coeficientes	4
3	Estimación por máxima verosimilitud	4
3.1	Log-verosimilitud	4
3.2	Vector score	4
3.3	Hessiano e información de Fisher	5
3.4	Newton–Raphson e IRLS	5
3.5	Distribución asintótica del MLE	5
4	La trinidad de tests asintóticos	6
4.1	Test de Wald	6
4.2	Test de Score (Rao)	6
4.3	Test de Razón de Verosimilitudes (LRT)	7
5	Diagnóstico visual: el <i>empirical logit plot</i>	7
6	Test de Box–Tidwell	8
6.1	Origen: transformación de Box y Tidwell (1962)	8
6.2	Linealización por serie de Taylor	8
6.3	El contraste y su estadístico	9
6.4	Un test o muchos: Wald escalar, Wald multivariado y LRT	9
6.5	Restricciones de aplicabilidad	11
6.6	Por qué incluir el resto de covariables (control)	11
6.7	Implementación en Python	11
7	Remedios ante violaciones	12

8	Bondad de ajuste global: test de Hosmer–Lemeshow	13
8.1	Por qué no sirve el χ^2 de Pearson clásico	13
8.2	Construcción del estadístico	13
8.3	Distribución y grados de libertad	13
8.4	¿Cuándo usar Hosmer–Lemeshow? ¿Es opcional?	14
8.5	Implementación en Python	15
9	Flujo de trabajo completo	15
10	Fuentes y lecturas recomendadas	16

1 Introducción y objetivo

Estas notas desarrollan, desde primeros principios, la maquinaria inferencial de la regresión logística y los tests de diagnóstico que verifican el supuesto central del modelo: la *linealidad en el logit*. El estándar de rigor es el de un curso de teoría de la verosimilitud: para cada estadístico se deriva su forma, se establece su distribución bajo H_0 y se justifica por qué se usa ese y no otro.

El hilo conductor es el siguiente flujo de trabajo, que ejecutaremos sobre un problema real de *scoring* de crédito (dataset *Home Credit Default Risk*):

1. Ajuste del modelo logístico por máxima verosimilitud (MLE), vía Newton–Raphson / IRLS.
2. Diagnóstico visual de linealidad en el logit (*empirical logit plot*).
3. Test formal de Box–Tidwell (basado en el test de Wald sobre un término construido).
4. Remedios ante violaciones (transformaciones, términos polinomiales).
5. Bondad de ajuste global (test de Hosmer–Lemeshow).

La **trinidad** de tests asintóticos —Wald, Score (Rao) y Razón de Verosimilitudes (LRT)— aparece transversalmente, de modo que la Sección 4 la desarrolla en general y las secciones siguientes la instancian.

2 El modelo logístico

2.1 Planteamiento y motivación del enlace

Sea $Y \in \{0, 1\}$ una respuesta binaria y $\mathbf{x} = (1, x_1, \dots, x_p)^\top \in \mathbb{R}^{p+1}$ un vector de predictores (con intercepto). Modelamos

$$Y_i \mid \mathbf{x}_i \stackrel{\text{iid}}{\sim} \text{Bernoulli}(\pi_i), \quad \pi_i = \Pr(Y_i = 1 \mid \mathbf{x}_i).$$

Un modelo lineal ingenuo $\pi_i = \mathbf{x}_i^\top \boldsymbol{\beta}$ falla por dos razones, ambas consecuencia de que Y es Bernoulli:

- **Rango:** $\mathbf{x}_i^\top \boldsymbol{\beta}$ recorre todo $\mathbb{R}$, pero $\pi_i \in (0, 1)$. Un modelo lineal produce probabilidades fuera de $[0, 1]$.
- **Heterocedasticidad:** $\text{Var}(Y_i) = \pi_i(1 - \pi_i)$ depende de π_i y por tanto de $\mathbf{x}_i$; no es constante. Esto viola el supuesto de homocedasticidad del modelo lineal (Gauss–Markov), inutilizando OLS.

La solución es introducir una **función de enlace** g que mapee $(0, 1) \rightarrow \mathbb{R}$. El enlace *canónico* para la familia Bernoulli es el **logit**:

$$\text{logit}(\pi_i) = \log \frac{\pi_i}{1 - \pi_i} = \mathbf{x}_i^\top \boldsymbol{\beta}$$

La cantidad $\pi/(1 - \pi)$ son los *odds* (momios), y $\log\{\pi/(1 - \pi)\}$ el *log-odds*. Invirtiendo:

$$\pi_i = \frac{e^{\mathbf{x}_i^\top \boldsymbol{\beta}}}{1 + e^{\mathbf{x}_i^\top \boldsymbol{\beta}}} = \frac{1}{1 + e^{-\mathbf{x}_i^\top \boldsymbol{\beta}}} = \sigma(\mathbf{x}_i^\top \boldsymbol{\beta}),$$

donde $\sigma(\cdot)$ es la función logística (sigmoide).

Observación 2.1 (¿Por qué el logit y no otro enlace?). El logit es el **enlace canónico** de la familia exponencial Bernoulli. Escribiendo la pmf de Bernoulli en forma canónica,

$$f(y; \pi) = \pi^y (1 - \pi)^{1-y} = \exp \left\{ y \underbrace{\log \frac{\pi}{1-\pi}}_{\theta} + \log(1 - \pi) \right\},$$

el parámetro natural es exactamente $\theta = \text{logit}(\pi)$. Modelar $\theta = \mathbf{x}^\top \boldsymbol{\beta}$ da simplificaciones notables: la información observada coincide con la esperada, y Newton–Raphson coincide con Fisher scoring (Sección 3.4). Otros enlaces son válidos (probit: $g = \Phi^{-1}$; complementario log-log) pero no canónicos.

2.2 Interpretación de los coeficientes

De $\text{logit}(\pi) = \mathbf{x}^\top \boldsymbol{\beta}$, un incremento unitario en x_j (con lo demás fijo) cambia el log-odds en β_j , es decir multiplica los *odds* por e^{β_j} . Por eso e^{β_j} se llama *odds ratio*. Este carácter **multiplicativo** (frente al aditivo de la regresión lineal) es esencial al interpretar variables transformadas: si el modelo usa $\log(x_j)$, entonces β_j mide el efecto de multiplicar x_j por e .

3 Estimación por máxima verosimilitud

A diferencia de la regresión lineal (donde OLS da forma cerrada), en logística no hay solución cerrada y se recurre al MLE resuelto numéricamente. Seguimos la teoría de verosimilitud estándar (cf. Rodríguez, Princeton, *GLM Notes*, Ap. A).

3.1 Log-verosimilitud

Como los Y_i son Bernoulli independientes, la verosimilitud es

$$L(\boldsymbol{\beta}) = \prod_{i=1}^n \pi_i^{y_i} (1 - \pi_i)^{1-y_i},$$

y la **log-verosimilitud**:

$$\begin{aligned} \ell(\boldsymbol{\beta}) &= \sum_{i=1}^n [y_i \log \pi_i + (1 - y_i) \log(1 - \pi_i)] \\ &= \sum_{i=1}^n \left[y_i \log \frac{\pi_i}{1-\pi_i} + \log(1 - \pi_i) \right] \\ &= \sum_{i=1}^n [y_i \mathbf{x}_i^\top \boldsymbol{\beta} - \log(1 + e^{\mathbf{x}_i^\top \boldsymbol{\beta}})], \end{aligned} \tag{1}$$

donde en la última línea usamos $\text{logit}(\pi_i) = \mathbf{x}_i^\top \boldsymbol{\beta}$ y $\log(1 - \pi_i) = -\log(1 + e^{\mathbf{x}_i^\top \boldsymbol{\beta}})$.

3.2 Vector score

El **score** es el gradiente de ℓ . Usando $\frac{\partial}{\partial \boldsymbol{\beta}} \log(1 + e^{\mathbf{x}_i^\top \boldsymbol{\beta}}) = \frac{e^{\mathbf{x}_i^\top \boldsymbol{\beta}}}{1 + e^{\mathbf{x}_i^\top \boldsymbol{\beta}}} \mathbf{x}_i = \pi_i \mathbf{x}_i$,

$$\mathbf{u}(\boldsymbol{\beta}) = \frac{\partial \ell}{\partial \boldsymbol{\beta}} = \sum_{i=1}^n (y_i - \pi_i) \mathbf{x}_i = \mathbf{X}^\top (\mathbf{y} - \boldsymbol{\pi}), \tag{2}$$

donde $\mathbf{X}$ es la matriz de diseño $n \times (p+1)$, $\mathbf{y} = (y_i)$ y $\boldsymbol{\pi} = (\pi_i)$. Las *ecuaciones de verosimilitud* $\mathbf{u}(\hat{\boldsymbol{\beta}}) = \mathbf{0}$ igualan los momentos observados y ajustados: $\mathbf{X}^\top \mathbf{y} = \mathbf{X}^\top \hat{\boldsymbol{\pi}}$.

Observación 3.1 (Media cero del score). Como $\mathbb{E}[Y_i] = \pi_i$, se tiene $\mathbb{E}[\mathbf{u}(\boldsymbol{\beta})] = \mathbf{X}^\top (\mathbb{E}[\mathbf{y}] - \boldsymbol{\pi}) = \mathbf{0}$ en el valor verdadero. Esta es la primera identidad de Bartlett, base de toda la teoría asintótica.

3.3 Hessiano e información de Fisher

Derivando (2) otra vez, y usando $\partial\pi_i/\partial\boldsymbol{\beta} = \pi_i(1 - \pi_i)\mathbf{x}_i$:

$$\mathbf{H}(\boldsymbol{\beta}) = \frac{\partial^2 \ell}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}^\top} = - \sum_{i=1}^n \pi_i(1 - \pi_i) \mathbf{x}_i \mathbf{x}_i^\top = -\mathbf{X}^\top \mathbf{W} \mathbf{X}, \quad (3)$$

donde $\mathbf{W} = \text{diag}(\pi_i(1 - \pi_i))$. Como $\mathbf{H}$ no depende de $\mathbf{y}$ (solo de $\boldsymbol{\pi}$, que depende de $\boldsymbol{\beta}$ y $\mathbf{X}$), la **información observada** $-\mathbf{H}$ coincide con la **información esperada** (de Fisher):

$$\mathbf{I}(\boldsymbol{\beta}) = \mathbb{E}[-\mathbf{H}(\boldsymbol{\beta})] = \mathbf{X}^\top \mathbf{W} \mathbf{X}. \quad (4)$$

Esta coincidencia es precisamente la propiedad del enlace canónico. Además $\mathbf{I}(\boldsymbol{\beta})$ es definida positiva (si $\mathbf{X}$ tiene rango completo y $0 < \pi_i < 1$), luego ℓ es cóncava y el MLE, cuando existe, es único.

3.4 Newton–Raphson e IRLS

Como $\mathbf{u}(\hat{\boldsymbol{\beta}}) = \mathbf{0}$ no tiene forma cerrada, expandimos el score en serie de Taylor de primer orden alrededor de un valor $\boldsymbol{\beta}^{(t)}$:

$$\mathbf{0} = \mathbf{u}(\hat{\boldsymbol{\beta}}) \approx \mathbf{u}(\boldsymbol{\beta}^{(t)}) + \mathbf{H}(\boldsymbol{\beta}^{(t)}) (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}^{(t)}),$$

y despejando obtenemos la iteración de **Newton–Raphson**:

$$\boldsymbol{\beta}^{(t+1)} = \boldsymbol{\beta}^{(t)} - \mathbf{H}^{-1}(\boldsymbol{\beta}^{(t)}) \mathbf{u}(\boldsymbol{\beta}^{(t)}) = \boldsymbol{\beta}^{(t)} + (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{y} - \boldsymbol{\pi}). \quad (5)$$

Al usar el enlace canónico, $\mathbf{H} = -\mathbf{I}$, por lo que Newton–Raphson coincide con **Fisher scoring**. La ecuación (5) puede reescribirse como un problema de mínimos cuadrados ponderados: definiendo la *variable de respuesta ajustada*

$$z_i^{(t)} = \mathbf{x}_i^\top \boldsymbol{\beta}^{(t)} + \frac{y_i - \pi_i^{(t)}}{\pi_i^{(t)}(1 - \pi_i^{(t)})},$$

se obtiene

$$\boldsymbol{\beta}^{(t+1)} = (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{z}^{(t)},$$

que es exactamente el estimador de mínimos cuadrados ponderados (WLS) de $\mathbf{z}^{(t)}$ sobre $\mathbf{X}$ con pesos $\mathbf{W}$. De ahí el nombre **IRLS** (*Iteratively Reweighted Least Squares*): en cada paso resolvemos una regresión lineal ponderada, actualizamos $\boldsymbol{\pi}$ y $\mathbf{W}$, y repetimos hasta convergencia. Este es el algoritmo que implementan `glm` en R y `statsmodels/sklearn` en Python.

3.5 Distribución asintótica del MLE

Teorema 3.2 (Normalidad asintótica del MLE). *Bajo condiciones de regularidad (parámetro verdadero interior al espacio, ℓ tres veces diferenciable con terceras derivadas acotadas), el MLE satisface*

$$\hat{\boldsymbol{\beta}} \stackrel{a}{\sim} \mathcal{N}_{p+1}(\boldsymbol{\beta}, \mathbf{I}^{-1}(\boldsymbol{\beta})), \quad \text{equivalentemente} \quad \sqrt{n}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) \xrightarrow{d} \mathcal{N}(\mathbf{0}, [n^{-1} \mathbf{I}(\boldsymbol{\beta})]^{-1}).$$

Idea de la demostración. Se expande $\mathbf{u}(\hat{\beta}) = \mathbf{0}$ alrededor de β : $\mathbf{0} = \mathbf{u}(\beta) + \mathbf{H}(\beta)(\hat{\beta} - \beta) + o_p$. Entonces $\sqrt{n}(\hat{\beta} - \beta) = [-n^{-1}\mathbf{H}]^{-1} n^{-1/2}\mathbf{u}(\beta) + o_p$. Por la ley de los grandes números $-n^{-1}\mathbf{H} \xrightarrow{p} n^{-1}\mathbf{I}$, y por el TCL aplicado a $\mathbf{u}(\beta) = \sum_i (y_i - \pi_i)\mathbf{x}_i$ (suma de términos independientes de media cero y varianza $\mathbf{I}$), $n^{-1/2}\mathbf{u}(\beta) \xrightarrow{d} \mathcal{N}(\mathbf{0}, n^{-1}\mathbf{I})$. Slutsky cierra el argumento. ■

En la práctica estimamos la covarianza por $\widehat{\text{Var}}(\hat{\beta}) = \mathbf{I}^{-1}(\hat{\beta}) = (\mathbf{X}^\top \hat{\mathbf{W}} \mathbf{X})^{-1}$, y el **error estándar** de $\hat{\beta}_j$ es

$$\text{SE}(\hat{\beta}_j) = \sqrt{[(\mathbf{X}^\top \hat{\mathbf{W}} \mathbf{X})^{-1}]_{jj}}.$$

Observación 3.3 (Qué es SE). El *error estándar* $\text{SE}(\hat{\beta}_j)$ es la desviación estándar *de la distribución muestral del estimador* $\hat{\beta}_j$ (no de los datos). Cuantifica cuánto variaría $\hat{\beta}_j$ entre muestras repetidas. Sale de la raíz del elemento diagonal j de la matriz de covarianza asintótica $\mathbf{I}^{-1}(\hat{\beta})$.

4 La trinidad de tests asintóticos

Sea $H_0 : \theta = \theta_0$ (o, más generalmente, restricciones sobre un subvector). Existen tres estadísticos clásicos, todos con distribución asintótica χ^2 bajo H_0 . Difieren en *dónde* evalúan la verosimilitud.

Test	Evalúa en	Requiere ajustar
Wald	$\hat{\beta}$ (irrestringido)	solo modelo grande
Score (Rao)	θ_0 (restringido)	solo modelo chico
LRT	ambos	ambos modelos

4.1 Test de Wald

Teorema 4.1 (Wald). *Bajo $H_0 : \theta = \theta_0$ y las condiciones del Teorema 3.2, el estadístico*

$$W = (\hat{\beta} - \theta_0)^\top \mathbf{I}(\hat{\beta}) (\hat{\beta} - \theta_0) \xrightarrow{d} \chi_r^2,$$

donde r es el número de restricciones.

Derivación. Del Teorema 3.2, $\hat{\beta} \stackrel{a}{\sim} \mathcal{N}(\theta_0, \mathbf{I}^{-1})$ bajo H_0 . Estandarizando, la forma cuadrática de un vector normal $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \Sigma)$ cumple $\mathbf{z}^\top \Sigma^{-1} \mathbf{z} \sim \chi_r^2$. Tomando $\mathbf{z} = \hat{\beta} - \theta_0$ y $\Sigma = \mathbf{I}^{-1}$ se obtiene el resultado. ■

Para una sola componente ($r = 1$), se toma la raíz con signo:

$$z_j = \frac{\hat{\beta}_j - \beta_{j,0}}{\text{SE}(\hat{\beta}_j)} \xrightarrow{d} \mathcal{N}(0, 1), \quad z_j^2 \xrightarrow{d} \chi_1^2.$$

Este es exactamente el *z-value* que reporta **statsmodels** en la tabla de coeficientes. Nótese el paralelo con el test *t* de regresión lineal: allí el estadístico sigue una *t* exacta (por normalidad de los errores); aquí solo tenemos normalidad *asintótica*, así que la referencia es $\mathcal{N}(0, 1)$ y no *t*.

4.2 Test de Score (Rao)

Teorema 4.2 (Score). *Bajo $H_0 : \theta = \theta_0$, el score satisface $\mathbf{u}(\theta_0) \stackrel{a}{\sim} \mathcal{N}(\mathbf{0}, \mathbf{I}(\theta_0))$, y el estadístico*

$$Q = \mathbf{u}(\theta_0)^\top \mathbf{I}^{-1}(\theta_0) \mathbf{u}(\theta_0) \xrightarrow{d} \chi_r^2.$$

Derivación. Bajo H_0 , $\mathbf{u}(\boldsymbol{\theta}_0) = \sum_i (y_i - \pi_{i,0}) \mathbf{x}_i$ es suma de términos independientes de media cero (identidad de Bartlett) y covarianza $\mathbf{I}(\boldsymbol{\theta}_0)$. Por el TCL, $\mathbf{u}(\boldsymbol{\theta}_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{I}(\boldsymbol{\theta}_0))$. La forma cuadrática correspondiente es χ_r^2 . ■

La gran ventaja: *no requiere calcular el MLE del modelo grande*, solo el del modelo restringido (a menudo trivial). Por eso es el motor de muchos tests de diagnóstico (incluido el enfoque de "variable construida" del Box-Tidwell).

4.3 Test de Razón de Verosimilitudes (LRT)

Teorema 4.3 (Wilks). Sean $\omega_1 \subset \omega_2$ modelos anidados. Bajo H_0 (el modelo pequeño es correcto),

$$G^2 = -2 \log \lambda = 2[\ell(\hat{\boldsymbol{\beta}}_{\omega_2}) - \ell(\hat{\boldsymbol{\beta}}_{\omega_1})] \xrightarrow{d} \chi_\nu^2, \quad \nu = \dim(\omega_2) - \dim(\omega_1).$$

Derivación (esbozo). Expandiendo $\ell(\hat{\boldsymbol{\beta}}_{\omega_1})$ alrededor de $\hat{\boldsymbol{\beta}}_{\omega_2}$ en Taylor de segundo orden y usando que el score se anula en el MLE, se obtiene $G^2 \approx (\hat{\boldsymbol{\beta}}_{\omega_2} - \hat{\boldsymbol{\beta}}_{\omega_1})^\top \mathbf{I}(\hat{\boldsymbol{\beta}}_{\omega_2}) (\hat{\boldsymbol{\beta}}_{\omega_2} - \hat{\boldsymbol{\beta}}_{\omega_1})$, que es asintóticamente equivalente al estadístico de Wald y por tanto χ_ν^2 . ■

Observación 4.4 (Equivalencia asintótica y elección). Los tres estadísticos convergen a la misma χ_r^2 bajo H_0 y son asintóticamente equivalentes. En muestras finitas difieren; simulaciones sugieren que el LRT suele ser preferible. La elección práctica se rige por el costo computacional (¿ya tengo ajustado el modelo grande, el chico, o ambos?) y por robustez. En muestras muy grandes —como el dataset de crédito con $n \approx 3 \times 10^5$ — los tres coinciden casi exactamente.

5 Diagnóstico visual: el *empirical logit plot*

El supuesto central de la regresión logística no es que X se relacione linealmente con Y (para eso está la curva sigmoide), sino que el **logit** sea lineal en cada predictor continuo:

$$\text{logit}(\pi(x)) = \beta_0 + \beta_1 x.$$

Idea del diagnóstico. Si agrupamos las observaciones en bins según x y en cada bin estimamos $\hat{p}_b = \bar{y}_b$ (proporción de éxitos), entonces bajo el modelo el logit empírico $\log\{\hat{p}_b/(1 - \hat{p}_b)\}$ debe ser aproximadamente lineal en el centro $\bar{x}_b$ del bin.

Por qué bins de igual frecuencia (qcut). La varianza del logit empírico en un bin depende del número de observaciones:

$$\text{Var}(\text{logit}(\hat{p}_b)) \approx \frac{1}{n_b \hat{p}_b (1 - \hat{p}_b)}$$

(por el método delta aplicado a logit). Bins con pocas observaciones dan puntos muy ruidosos. Usar cuantiles (`pd.qcut`) garantiza n_b aproximadamente constante y estabiliza la varianza; usar bins de igual ancho (`pd.cut`) dejaría bins casi vacíos en las colas.

Listing 1: Empirical logit plot con manejo de NaN e infinitos.

```
1 import numpy as np
2 import pandas as pd
3 import matplotlib.pyplot as plt
4
5 def empirical_logit_plot(X_col, y, n_bins=10):
6     df = pd.DataFrame({"X": X_col, "y": y})
```

```

7      # Robustez: eliminar NaN e infinitos (p.ej. log de valores <= 0)
8      df = df.replace([np.inf, -np.inf], np.nan).dropna()
9
10     # Bins de igual frecuencia; duplicates='drop' evita errores por empates
11     df["bin"] = pd.qcut(df["X"], q=n_bins, duplicates="drop")
12     grouped = df.groupby("bin", observed=True).agg(
13         p=("y", "mean"),
14         X_mid=("X", "mean"),
15     )
16     # Solo bins con p en (0,1): el logit no existe en 0 ni 1
17     grouped = grouped[(grouped["p"] > 0) & (grouped["p"] < 1)]
18     grouped["logit"] = np.log(grouped["p"] / (1 - grouped["p"]))
19
20     plt.figure()
21     plt.scatter(grouped["X_mid"], grouped["logit"])
22     coef = np.polyfit(grouped["X_mid"], grouped["logit"], 1)
23     xs = np.unique(grouped["X_mid"])
24     plt.plot(xs, np.polyval(coef)(xs), "r--")
25     plt.xlabel(X_col.name); plt.ylabel("logit empirico")
26     plt.title(f"Logit empirico vs {X_col.name}")
27     plt.show()

```

Limitación. Con n grande y solo 10 bins, cada punto resume decenas de miles de observaciones y el diagrama puede verse ruidoso aun cuando la relación sea lineal. El visual es *preliminar*; la decisión formal la da el test de Box–Tidwell (Sección 6).

6 Test de Box–Tidwell

6.1 Origen: transformación de Box y Tidwell (1962)

Box y Tidwell (1962, *Technometrics* 4, 531–550) propusieron estimar la potencia λ de una transformación $x \mapsto x^\lambda$ que linealiza la relación. En el contexto logístico, supongamos que la forma verdadera es

$$\text{logit}(\pi) = \beta_0 + \beta_1 x^\lambda,$$

y queremos contrastar $H_0 : \lambda = 1$ (linealidad). El problema es que λ entra de forma *no lineal* en los parámetros, lo que complicaría la estimación. La solución de Box–Tidwell es **linealizar por Taylor**.

6.2 Linealización por serie de Taylor

Expandimos x^λ como función de λ alrededor de $\lambda = 1$. Recordando que $\frac{d}{d\lambda} x^\lambda = x^\lambda \log x$, evaluado en $\lambda = 1$ da $x \log x$:

$$x^\lambda \approx x^1 + (\lambda - 1) [x \log x] = x + (\lambda - 1) x \log x.$$

Sustituyendo en el modelo:

$$\text{logit}(\pi) \approx \beta_0 + \beta_1 x + \underbrace{\beta_1(\lambda - 1)}_{\gamma} (x \log x).$$

Definiendo $\gamma = \beta_1(\lambda - 1)$, el modelo se vuelve **lineal en los parámetros** $(\beta_0, \beta_1, \gamma)$, con un *término construido* adicional $x \log x$:

$$\boxed{\text{logit}(\pi) = \beta_0 + \beta_1 x + \gamma (x \log x)} \quad (6)$$

6.3 El contraste y su estadístico

Bajo esta parametrización, la hipótesis de linealidad $\lambda = 1$ equivale a

$$H_0 : \gamma = 0 \quad \text{vs} \quad H_a : \gamma \neq 0.$$

Como (6) es un modelo logístico ordinario (con $x \log x$ como un predictor más), el contraste sobre γ es un **test de Wald** estándar sobre un coeficiente individual:

$$z = \frac{\hat{\gamma}}{\text{SE}(\hat{\gamma})} \xrightarrow{d} \mathcal{N}(0, 1) \quad \text{bajo } H_0, \quad z^2 \xrightarrow{d} \chi_1^2.$$

Rechazar H_0 ($p < 0.05$) indica que el término $x \log x$ mejora significativamente el ajuste, es decir, **hay violación de la linealidad en el logit**. Equivalentemente puede usarse el LRT comparando (6) con el modelo sin $x \log x$; ambos son asintóticamente χ_1^2 .

Observación 6.1 (¿Por qué este estadístico y no un test directo sobre λ ?). Un test de Wald/LRT directo sobre λ exigiría estimar el modelo no lineal $\beta_0 + \beta_1 x^\lambda$, con optimización más costosa e inestable. El truco de Box–Tidwell convierte el problema en *añadir una covariable construida* y testear su coeficiente con la maquinaria ya disponible. El costo: es una prueba *local* (válida cerca de $\lambda = 1$) y de primer orden.

6.4 Un test o muchos: Wald escalar, Wald multivariado y LRT

Al ajustar el **único** modelo aumentado con todos los términos construidos,

$$\text{logit}(\pi) = \beta_0 + \sum_{j=1}^m \beta_j x_j + \sum_{j=1}^m \gamma_j (x_j \log x_j),$$

disponemos de un vector $\gamma = (\gamma_1, \dots, \gamma_m)^\top$. Sobre este *mismo* modelo pueden plantearse dos hipótesis distintas, y conviene no confundirlas.

(A) Hipótesis univariada (una por variable).

$$H_0^{(j)} : \gamma_j = 0 \quad (r = 1).$$

Es el **Wald escalar** sobre un coeficiente individual, ya derivado en la Sección 4:

$$z_j = \frac{\hat{\gamma}_j}{\text{SE}(\hat{\gamma}_j)} \xrightarrow{d} \mathcal{N}(0, 1), \quad z_j^2 \xrightarrow{d} \chi_1^2,$$

donde $\text{SE}(\hat{\gamma}_j) = \sqrt{[\mathbf{I}^{-1}(\hat{\beta})]_{jj}}$. Testea la linealidad de *una* variable, controlando por todo lo demás (incluidos los otros γ_k). Es el que reporta `statsmodels` en `.pvalues`, y el que guía la decisión de *cuál* variable transformar.

(B) Hipótesis conjunta (todas a la vez).

$$H_0 : \gamma_1 = \gamma_2 = \dots = \gamma_m = 0 \quad (r = m).$$

La hipótesis es que *ninguna* variable viola linealidad simultáneamente. Aquí sí aparece un **Wald multivariado**. Escribiendo la restricción en forma matricial $H_0 : \mathbf{C}\hat{\beta} = \mathbf{0}$, donde $\mathbf{C}$ es la matriz

$m \times (2m + 1)$ que selecciona las componentes γ del vector completo, el estadístico es la **forma cuadrática**

$$W = \hat{\gamma}^\top [\widehat{\text{Var}}(\hat{\gamma})]^{-1} \hat{\gamma} \xrightarrow{d} \chi_m^2, \quad (7)$$

con $\widehat{\text{Var}}(\hat{\gamma})$ el bloque $m \times m$ de la covarianza $\mathbf{I}^{-1}(\hat{\beta}) = (\mathbf{X}^\top \mathbf{W} \mathbf{X})^{-1}$ correspondiente a γ .

Derivación. Por el Teorema 3.2, $\hat{\beta} \stackrel{a}{\sim} \mathcal{N}(\beta, \mathbf{I}^{-1})$. Una transformación lineal de un vector normal es normal: $\mathbf{C}\hat{\beta} \stackrel{a}{\sim} \mathcal{N}(\mathbf{C}\beta, \mathbf{C}\mathbf{I}^{-1}\mathbf{C}^\top)$. Bajo H_0 , $\mathbf{C}\beta = \mathbf{0}$, y como $\mathbf{C}$ selecciona el subvector γ , $\mathbf{C}\mathbf{I}^{-1}\mathbf{C}^\top = \widehat{\text{Var}}(\hat{\gamma})$ es justo el bloque diagonal. La forma cuadrática de un normal $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \Sigma)$ cumple $\mathbf{z}^\top \Sigma^{-1} \mathbf{z} \sim \chi_m^2$; con $\mathbf{z} = \hat{\gamma}$ se obtiene (7). ■

Este es el análogo logístico exacto del estadístico F que en regresión lineal contrasta un *bloque* de coeficientes simultáneamente (allí F exacta por normalidad de los errores; aquí χ_m^2 solo asintótica).

El LRT conjunto: alternativa equivalente. La misma hipótesis conjunta $H_0 : \gamma = \mathbf{0}$ puede contrastarse por razón de verosimilitudes, comparando el modelo aumentado (grande) con el modelo sin los m términos construidos (chico):

$$G^2 = 2[\ell(\text{aumentado}) - \ell(\text{reducido})] \xrightarrow{d} \chi_m^2.$$

Por la equivalencia asintótica de la trinidad (Sección 4), W de (7) y G^2 convergen a la misma χ_m^2 bajo H_0 . En la implementación de la Sección 6 usamos el **LRT** para la parte conjunta —no el Wald multivariado— simplemente porque ya teníamos ambos modelos ajustados y resulta más económico; ambas respuestas son válidas e intercambiables.

Observación 6.2 (Escalar y conjunto no son redundantes). Puede ocurrir que *ningún* Wald escalar rechace ($p_j > 0.05$ para todo j) pero el test conjunto *sí* rechace: violaciones pequeñas y correlacionadas suman evidencia. Y a la inversa, un escalar aislado puede rechazar sin que el conjunto lo haga. Es el mismo fenómeno que en regresión lineal, donde el F global puede ser significativo con todos los t individuales no significativos (multicolinealidad). La forma cuadrática (7) captura la covarianza entre los $\hat{\gamma}_j$ vía el bloque $\widehat{\text{Var}}(\hat{\gamma})$, información que los tests escalares uno a uno ignoran.

Pregunta	Hipótesis	Test	Distr. bajo H_0
¿Esta variable viola linealidad?	$\gamma_j = 0$	Wald escalar	χ_1^2
¿Alguna variable viola linealidad?	$\gamma = \mathbf{0}$	Wald multivariado o LRT	χ_m^2

Para el flujo de decisión (transformar variable por variable) se necesita el **Wald escalar**, porque interesa saber *cuál* corregir. El test conjunto sirve de chequeo global: si el χ_m^2 no rechaza, puede detenerse el análisis sin revisar variable por variable.

Wald multivariado explícito en Pythor

```

1 # Sobre el modelo aumentado m_full (con los terminos X*ln(X)):
2 terminos = [c for c in m_full.params.index if c.endswith("_ln")]
3
4 # H0 conjunta: todos los gamma = 0 -> Wald multivariado (chi^2 con m gl)
5 wald_conjunto = m_full.wald_test(
6     ", ".join(f"{t} = 0" for t in terminos),
7     scalar=True,
8 )
9 print(wald_conjunto) # estadístico chi^2, gl = m, y su p-valor
    
```

Internamente `wald_test` construye $\mathbf{C}$, extrae el bloque de covarianza y evalúa la forma cuadrática (7).

6.5 Restricciones de aplicabilidad

El término $x \log x$ requiere $x > 0$. Por tanto:

- **Continuas positivas:** aplica directamente.
- **Con ceros/negativos:** desplazar ($x \mapsto x - \min + c$) o usar la versión con enlace/otra transformación. Si el cero es *estructural* (p.ej. `amt_goods_price=0` para préstamos en efectivo), la práctica correcta es separar en un flag binario más la variable transformada donde $x > 0$.
- **Binarias / dummies: no aplica.** Con solo dos valores, dos puntos siempre determinan una recta; no hay curva que linealizar, y $\log 0$ no existe. El supuesto de linealidad en el logit es un supuesto *sobre variables continuas*.

6.6 Por qué incluir el resto de covariables (control)

El test debe correrse en el **modelo completo**: se incluyen todos los predictores y se añade $x_j \log x_j$ para cada continua a testear. Omitir covariables relevantes induce el **sesgo por variable omitida** (misma lógica que en regresión lineal múltiple): si x_j está correlacionada con una covariable ausente x_k , entonces $\hat{\gamma}_j$ absorbe parte del efecto de x_k y el test detecta "no-linealidad" espuria. Esto es coherente con el supuesto formal—"no se omiten variables importantes"—listado en los tratamientos de diagnóstico logístico (UCLA OARC; University of Guelph).

El test de Wald sobre cada $\hat{\gamma}_j$, en el modelo aumentado conjunto, contrasta la linealidad *marginal* de x_j *dado todo lo demás*, que es la pregunta correcta. Esta versión conjunta (todos los términos $x_j \log x_j$ a la vez) es válida y es la recomendada para modelos multivariados; equivale a correr un test por variable pero controlando simultáneamente por los demás términos construidos.

6.7 Implementación en Python

Listing 2: Box–Tidwell conjunto con Wald por término y LRT global.

```

1  import numpy as np
2  import pandas as pd
3  import statsmodels.api as sm
4  import scipy.stats as stats
5
6  def box_tidwell_test(df, y, cols_a_testear, cols_control=None):
7      """
8      H0: gamma_j = 0 (linealidad en el logit) para cada X_j continua > 0.
9      - cols_a_testear: continuas positivas -> se agrega X*ln(X).
10     - cols_control: entran como control, NO se testean (negativas, dummies).
11     """
12     X = pd.DataFrame(index=df.index)
13     if cols_control:
14         for c in cols_control:
15             X[c] = df[c]
16
17     interaction_cols = []
18     for c in cols_a_testear:
19         v = df[c]
20         if not (v > 0).all():
21             print(f"[omitida] {c}: tiene valores <= 0")
22             continue
23         X[c] = v
24         X[f"{c}_ln"] = v * np.log(v)

```

```

25     interaction_cols.append(f"{c}_ln")
26
27     # Eliminar filas con NaN en cualquier columna usada
28     X["_y"] = y
29     X = X.dropna()
30     y_clean = X.pop("_y")
31
32     Xc = sm.add_constant(X)
33     m_full = sm.Logit(y_clean, Xc).fit(dis=0)
34
35     print("== Box-Tidwell: Wald por termino (z = gamma/SE ~ N(0,1)) ==")
36     resultados = {}
37     for col in interaction_cols:
38         var = col.replace("_ln", "")
39         g, se = m_full.params[col], m_full.bse[col]
40         z, p = m_full.tvalues[col], m_full.pvalues[col]
41         flag = "*** VIOLACION" if p < 0.05 else "OK"
42         print(f"    {var:22s}: gamma={g:+.5f}  z={z:7.3f}  p={p:.4f}  {flag}")
43         resultados[var] = {"gamma": g, "se": se, "z": z, "p": p}
44
45     # LRT global: H0 todos los gamma = 0
46     m_red = sm.Logit(y_clean, Xc.drop(columns=interaction_cols)).fit(dis=0)
47     lr = 2 * (m_full.llf - m_red.llf)
48     gl = len(interaction_cols)
49     p_lrt = stats.chi2.sf(lr, df=gl)
50     print(f"\n== LRT global: G2={lr:.3f}, gl={gl}, p={p_lrt:.4f} ==")
51
52     return m_full, m_red, resultados

```

Listing 3: Decisión post-test con criterio de magnitud (clave en n grande).

```

1  cols_finales = list(cols_control)
2  for var, r in resultados.items():
3      if r["p"] >= 0.05:
4          print(f"{var}: OK -> entra sin transformacion adicional")
5          cols_finales.append(var)
6      elif abs(r["gamma"]) < 1e-2:
7          # Significativo pero magnitud trivial: en n grande el Wald
8          # detecta violaciones minúsculas. Practicamente irrelevante.
9          print(f"{var}: p<0.05 pero |gamma|~0 -> violacion irrelevante")
10         cols_finales.append(var)
11     else:
12         # Violacion real -> remedio (termino cuadratico, spline, excluir)
13         print(f"{var}: VIOLACION real -> aplicar remedio")
14         df[f"{var}_sq"] = df[var] ** 2
15         cols_finales += [var, f"{var}_sq"]

```

Observación 6.3 (Sensibilidad al tamaño de muestra). El test de Box–Tidwell **no es robusto al tamaño muestral**: con n grande, $SE(\hat{\gamma})$ es diminuto y el Wald declara significativas violaciones de magnitud ínfima. La guía práctica (SPSS, literatura aplicada) es: con muestras grandes, no preocuparse por una interacción *apenas* significativa; mirar la *magnitud* de $\hat{\gamma}$ junto con el p -valor. Con $n \approx 3 \times 10^5$ esto es esencial.

7 Remedios ante violaciones

Si el test rechaza linealidad con magnitud no trivial, las opciones ordenadas de menor a mayor complejidad:

- a. **Transformación** del predictor (log, raíz, recíproco). Es el primer intento natural y suele bastar para variables de escala amplia (montos, ingresos).
- b. **Término polinomial**: añadir x^2 (o mayor) al modelo, que captura curvatura en el logit. Concuerda con la literatura (Hosmer–Lemeshow; notas de UCLA/Guelph).
- c. **Spline cúbico restringido**: más flexible que un polinomio global, con mejor comportamiento en las colas.
- d. **Excluir la variable** si, además de no-lineal, no aporta poder predictivo (confirmar con LRT del modelo con y sin ella).

Tras aplicar un remedio, se **re-gráfica** el logit empírico de la variable transformada y se **re-testea** con Box–Tidwell hasta que el supuesto se sostenga.

Interpretación tras transformar. La transformación pasa a ser parte de la *especificación* del modelo: se aplica idénticamente en entrenamiento, validación, test y producción (idealmente encapsulada en un **Pipeline** de **sklearn**). El coeficiente de $\log(x_j)$ mide el efecto de multiplicar x_j por e sobre el log-odds; no es comparable en escala con el de una variable sin transformar.

8 Bondad de ajuste global: test de Hosmer–Lemeshow

8.1 Por qué no sirve el χ^2 de Pearson clásico

Para evaluar bondad de ajuste global se compara frecuencias observadas y esperadas. Con predictores *continuos*, casi cada observación tiene un patrón de covariables único, generando una tabla de contingencia dispersa (celdas con conteos 0 o 1). En ese régimen, los estadísticos X^2 de Pearson y G^2 de devianza **no** tienen distribución χ^2 aproximada, porque el número de celdas crece con n y las frecuencias esperadas por celda no crecen. Hosmer y Lemeshow (1980) propusieron agrupar para restaurar la aproximación.

8.2 Construcción del estadístico

1. Ajustar el modelo y calcular las probabilidades ajustadas $\hat{\pi}_i$ para toda observación.
2. Ordenar por $\hat{\pi}_i$ y partir en g grupos de igual tamaño (típicamente $g = 10$, *deciles de riesgo*).
3. En cada grupo k : observados $O_k = \sum_{i \in k} y_i$; esperados $E_k = \sum_{i \in k} \hat{\pi}_i = n_k \bar{\pi}_k$, con $\bar{\pi}_k$ la probabilidad media del grupo.

El estadístico es una suma tipo Pearson sobre éxitos y fracasos de cada grupo:

$$\hat{C} = \sum_{k=1}^g \frac{(O_k - n_k \bar{\pi}_k)^2}{n_k \bar{\pi}_k (1 - \bar{\pi}_k)}. \quad (8)$$

8.3 Distribución y grados de libertad

Teorema 8.1 (Hosmer–Lemeshow, 1980). *Si el modelo logístico es correcto, las frecuencias esperadas por celda son suficientemente grandes y $g > p + 1$, entonces (establecido por simulación)*

$$\hat{C} \stackrel{a}{\sim} \chi_{g-2}^2.$$

La reducción a $g - 2$ grados de libertad (en vez de g) se debe a que las probabilidades ajustadas se estimaron del propio modelo, lo que impone dos restricciones adicionales (aproximadamente correspondientes al intercepto y a la pendiente del ajuste sobre los grupos). Un p -valor *grande* indica buen ajuste (no se rechaza que observado $\approx$ esperado). Nótese la lógica invertida frente a un test de significancia usual: aquí *no* rechazar es lo deseable.

Observación 8.2 (Limitaciones). El test de Hosmer–Lemeshow (i) evalúa calibración global, no una forma específica de mala especificación (p.ej. un término cuadrático faltante); (ii) es sensible al número y método de agrupamiento; (iii) en muestras muy grandes tiende a rechazar por desviaciones triviales, y en muy pequeñas tiene poca potencia. Es complementario —no sustituto— del diagnóstico de linealidad. Harrell recomienda además examinar residuos y calibración gráfica.

8.4 ¿Cuándo usar Hosmer–Lemeshow? ¿Es opcional?

Sí, es un test **opcional y complementario**, no un requisito para que la regresión logística sea válida. Conviene ubicarlo bien dentro del flujo:

- **Los supuestos que validan el modelo** son los de las Secciones 5–7: linealidad en el logit (Box–Tidwell), independencia de observaciones, ausencia de multicolinealidad (VIF) y tamaño muestral suficiente. Estos son *previos* al ajuste y condicionan que la inferencia sobre $\hat{\beta}$ sea confiable.
- **Hosmer–Lemeshow es *posterior***: se corre sobre el modelo ya ajustado para chequear *calibración global* —si las probabilidades predichas coinciden con las frecuencias observadas por grupos de riesgo. No sustituye a los diagnósticos de supuestos.

Cuándo sí aporta.

- **Modelos de predicción de riesgo** donde la probabilidad predicha se usa como tal (credit scoring, riesgo clínico, seguros). Ahí la calibración es el objetivo mismo: un $\hat{\pi} = 0.1$ debe corresponder a $\approx 10\%$ de eventos observados. Es su caso de uso canónico y por eso aparece en la validación de *scorecards*.
- Cuando hay **predictores continuos** que hacen inaplicable el χ^2 de Pearson clásico (Sección 8), y se quiere una medida de ajuste global resumida en un número.

Cuándo es prescindible o engañoso.

- **Objetivo puramente discriminativo** (ordenar/clasificar, no usar la probabilidad como magnitud): interesan más AUC, sensibilidad y especificidad. Un modelo puede discriminar bien (AUC alto) y estar mal calibrado, o viceversa: son propiedades distintas.
- **Muestras muy grandes** (como el dataset de crédito, $n \approx 3 \times 10^5$): el test rechaza por desviaciones triviales —mismo problema de sensibilidad al tamaño que el Box–Tidwell. Con n grande conviene apoyarse en **gráficas de calibración** (probabilidad predicha vs observada por bin) en lugar del p -valor, que casi siempre saldrá significativo.
- **Diagnóstico de una forma concreta de mala especificación**: para eso sirven Box–Tidwell (linealidad) o añadir términos y comparar por LRT, no Hosmer–Lemeshow, que solo detecta descalibración agregada.

En resumen: para el flujo de *este* documento —verificar linealidad en el logit— el test relevante es Box–Tidwell. Hosmer–Lemeshow es un chequeo *final y opcional* de calibración, especialmente

pertinente si el producto es un modelo de scoring cuyas probabilidades se interpretan literalmente; con n grande, complementarlo (o reemplazarlo) por una curva de calibración.

8.5 Implementación en Python

Listing 4: Test de Hosmer-Lemeshow.

```

1  import numpy as np
2  import pandas as pd
3  import scipy.stats as stats
4
5  def hosmer_lemeshow(y_true, y_prob, g=10):
6      df = pd.DataFrame({"y": np.asarray(y_true), "p": np.asarray(y_prob)})
7      # Deciles de riesgo (igual numero de obs por grupo)
8      df["grupo"] = pd.qcut(df["p"], q=g, duplicates="drop")
9
10     agg = df.groupby("grupo", observed=True).agg(
11         n=("y", "size"),
12         obs=("y", "sum"),
13         p_bar=("p", "mean"),
14     )
15     agg["esp"] = agg["n"] * agg["p_bar"]
16     # Estadístico de Hosmer-Lemeshow
17     C = (((agg["obs"] - agg["esp"]) ** 2)
18         / (agg["n"] * agg["p_bar"] * (1 - agg["p_bar"]))).sum()
19
20     gl = len(agg) - 2
21     p_val = stats.chi2.sf(C, df=gl)
22     print(f"Hosmer-Lemeshow: C={C:.3f}, gl={gl}, p={p_val:.4f}")
23     print("p grande -> no se rechaza buen ajuste (calibracion adecuada)")
24     return C, gl, p_val
25
26 # Uso tipico tras ajustar el modelo final:
27 # m = sm.Logit(y, sm.add_constant(X)).fit()
28 # hosmer_lemeshow(y, m.predict(sm.add_constant(X)), g=10)

```

9 Flujo de trabajo completo

Reuniendo todo, el procedimiento para verificar y conseguir la linealidad en el logit es:

1. **Clasificar variables:** continuas (candidatas al supuesto), binarias/dummies (exentas), y detectar valores anómalos o ceros estructurales que requieran limpieza o flags.
2. **Visual:** *empirical logit plot* de cada continua. Confirma las lineales y señala las sospechosas.
3. **Transformar** las visualmente no-lineales (típicamente log en variables de escala amplia) y re-graficar.
4. **Box-Tidwell conjunto** sobre las continuas positivas del modelo final, incluyendo todas las demás como control. Wald por término + LRT global.
5. **Decidir por variable** combinando p -valor y *magnitud* de $\hat{\gamma}$ (crítico en n grande): $p \geq 0.05$ o $|\hat{\gamma}| \approx 0 \Rightarrow$ aceptar; violación real $\Rightarrow$ remedio (polinomio, spline, o excluir).
6. **Iterar 3–5** hasta que el supuesto se sostenga.

7. **Ajustar el modelo final** y verificar bondad de ajuste global con Hosmer–Lemeshow, además de multicolinealidad (VIF), independencia y tamaño muestral (regla ≥ 10 eventos por predictor).
8. **Inferencia:** Wald/LRT sobre los $\hat{\beta}$ y odds ratios $e^{\hat{\beta}_j}$ con sus intervalos de confianza.

Etapa	Estadístico	Distribución bajo H_0
Coefficientes individuales	Wald $z = \hat{\beta}_j/\text{SE}$	$\mathcal{N}(0, 1)$
Bloque de coeficientes	LRT G^2	χ^2_ν
Box–Tidwell (por variable)	Wald $z = \hat{\gamma}/\text{SE}$	$\mathcal{N}(0, 1)$
Box–Tidwell (global)	LRT G^2	$\chi^2_{\#\text{términos}}$
Bondad de ajuste	Hosmer–Lemeshow $\hat{C}$	χ^2_{g-2}

10 Fuentes y lecturas recomendadas

Recursos con *derivación completa* (no solo enunciado), útiles para profundizar al nivel de estas notas:

- **G. Rodríguez (Princeton)**, *Generalized Linear Model Notes*, **Apéndice A**. Deriva score, información, Newton–Raphson/Fisher scoring y los tres tests con ejemplos. <https://grodri.github.io/glms/notes/a1.pdf>
- **Penn State STAT 504, Lecciones 6–7**. Modelo logístico desde el problema de heterocedasticidad de OLS, MLE, Wald y LRT, residuos y Hosmer–Lemeshow. <https://online.stat.psu.edu/stat504/>
- **MIT OCW 18.650 (Rigollet)**, **Lecturas 21–24, GLMs**. Familia exponencial, enlace canónico, información de Fisher, devianza; en video.
- **Shao, *Mathematical Statistics*, Lec. 26** (notas U. Wisconsin): pruebas formales de Wald y Score como χ^2 . <https://pages.stat.wisc.edu/~shao/stat610/stat610-26.pdf>
- **Box & Tidwell (1962)**, *Transformation of the Independent Variables*, Technometrics 4:531–550 (fuente primaria de la transformación).
- **Pregibon (1980)**, *Goodness of Link Tests for GLM*, JRSS-C 29:15–24 (extensión del test a GLM vía linealización).
- **Hosmer & Lemeshow (1980)** y Hosmer et al. (1997), sobre el estadístico de bondad de ajuste y su distribución.

Documento generado como material de estudio. Las derivaciones siguen el estándar de la teoría de verosimilitud; los recursos citados contienen las demostraciones formales completas.